

S.V.E.: как проверять мысли так же строго, как код — SIP/EBP, «Git для итеративных фактов»

Средний

Data Mining*, Искусственный интеллект, Машинное обучение*, Научно-популярное

Ожидает модерации

Основные материалы v0.3-0.4

 **GitHub репозиторий:**

github.com/skovnats/SVE-Systemic-Verification-Engineering

<https://github.com/skovnats/SVE-Systemic-Verification-Engineering/tree/master/Papers>

Препринты (часть — в модерации на arXiv, остальные — в подготовке), структура дисциплины и полные документация.

 Лицензия: **S.V.E. Public License v1.3** — свободно для некоммерческого использования.

 **Независимые AI-рецензии:**

[Reviews \(GPT-5, Claude, Gemini, Grok, Qwen\)](#)

<https://github.com/skovnats/SVE-Systemic-Verification-Engineering/tree/master/Reviews>

Пять независимых моделей делали ревью каждой статье и Qwen выносил финальный "вердикт" по результатам 4-ёх ревью.

 **Бот “Socrates” (рабочий прототип):**

chat.openai.com/g/g-68f1fc9848948191a1cc038db8e3422b-sokrat-socrates-bot-v0-2

Содержит все материалы S.V.E. (кроме статей 10–12 — в процессе) и работает как **когнитивная гимназия** — переводит сложные философские и математические концепции на человеческий язык.

 **Пример взаимодействия:**

Что в вас интересного? Какие данные загружены?

<https://chatgpt.com/share/68f2558c-add8-8003-91d8-ba4e7f03d6e1>

 **Важно:**

Автор **не отстаивает** идеологическую позицию, а предлагает **воспроизводимую методологию**, которая динамически обновляет вероятности тезисов при поступлении новых данных (*апостериорное уточнение*).

Любой может проверить результаты, повторив метод и подставив собственные данные.

Это **приглашение к научному диалогу**, а не защита взгляда.

Именно так и должна работать наука — через проверяемость, открытость и честное несогласие.

TL;DR

- **Проблема:** LLM уверенно ошибаются; люди подтверждают убеждения.
- **Решение:** S.V.E. — процедура верификации мышления: не ответы, а **путь к ответу**.
- **Инструменты:** **SIP** — итеративная очистка тезиса (в семантическом многообразии). **EBP** — интеллектуальный бокс — со судейской панелью.
- **Метрика: Integrity Score** — количественная оценка честности рассуждения.
- **Формат: когнитивная гимназия** — человек и ИИ взаимно тренируются.
- **Open-source:** код, статьи, диалоги, AI-рецензии, работающий бот.

1. Почему «спроси у ChatGPT» — это не решение

ChatGPT — не база знаний, а предсказатель слов (токенов). Он может объяснить квантовую механику, но также уверенно придумать несуществующую статью.

Проблема не только в нём — мы сами подыгрываем: часто задаём вопросы, чтобы получить **подтверждение**, а не опровержение.


Добавим шум соцсетей, политкорректности, коммерческие фильтры и встроенные смещения (bias) моделей — и получаем интеллектуальный Plinko, где жетон истины отскакивает от штырьков искажений.

Пример коррекции смещения модели через SIP:

https://github.com/skovnats/SVE-Systemic-Verification-Engineering/blob/master/Reviews/context/Mini-SocraticDialogue_PracticalExample.pdf

2. Решение: три персоны мудрости

S.V.E. предлагает не «ещё один ИИ-бот», а структуру верификации мышления:



- **Сократ** — логик и скептик: спрашивает «почему ты так думаешь?» и проверяет факты.
- **Соломон** — арбитр — оценивает не только логическую, но и нравственную корректность.
- **Иван-Дурак** — эмпатический фильтр: гарантирует, что истина доставляется «чайными ложечками».

Главный принцип — **1 + 1 > 2**: человек и ИИ взаимно корректируют друг друга и вместе становятся умнее.

 **Как работает Тройной Архитектор**

Каждый диалог с системой начинается с **оцифровки априорных убеждений**.

Пользователь указывает до 7 гипотез — и оценку уверенности в каждой (например 0.8 ± 0.1). Так создаётся карта *Priors*, с которой система работает как байесовский аудитор: вероятности пересчитываются после каждого шага анализа и/или добавления новых входных данных (факты, ценности и т.д.).

Далее применяется **Пятиколончатая таблица аудита**, разделяющая всё, что обычно смешано:

1 — Caesar's	2 — Experts	3 — Divine / Values	4 — Blind Spots	5 — Final Weight
Факты и данные	Консенсус / модели	Ценности и аксиомы	Противоречия и стресс-тесты	Итоговый вес для синтеза

Такое разделение делает видимыми «смещённые аргументы» — где эмоция, а где доказательство. На этой основе строится **Solomonic Verdict** — взвешенное заключение, где логика, этика и контекст сходятся в едином выводе.

Система постоянно **перекалибрует глубину и тон**, отслеживая стиль, орфографию и ритм мышления собеседника.

Если человек растёт — ИИ понижает «скидку уверенности» (Dunning–Kruger correction) и увеличивает сложность.

В конце каждого цикла появляются две «сократовские подписи», я называю это «Сократовский хвостик» (поскольку Сократу приписывается фраза: "я знаю, что ничего не знаю"):

- **Хвост человека:** предложение 1-3 факторов, которые он **не учёл**.
- **Хвост бота:** вопрос о том, что сам ИИ мог **переоценить** или **упустить**.


Так закрывается петля **1 + 1 > 2**: взаимная коррекция человека и машины.

3. Как это работает: два протокола

 **SIP — Socratic Investigative Process**

Итеративная очистка нарратива-тезиса от ошибок.

Каждое утверждение — это вектор в многомерном смысловом пространстве:



На каждой итерации система (Человек + ИИ) возможно находит конкретную ошибку — логическую, фактическую, контекстную — и "вычитает" её:

$$V(n+1) = V(n) - \varepsilon(n)$$

Простыми словами: каждое уточнение приближает нас к **устойчивому факту**.

Базовая геодезия для их возраста — 0.5 в год, даже с десятикратным стресс-множителем вероятность двух смертей подряд — ~3.9 × 10⁻⁹.

Вывод: теперь не конспирологи доказывают умысел, а скептики — объясняют статистическую аномалию.

SIP:

<https://github.com/skovnats/SVE-Systemic-Verification-Engineering/blob/master/Papers/SVE-0-2.pdf>

EBP — Epistemological Boxing Protocol

Если SIP — это очистка, то EBP — стресс-тест ("red-teaming").

Это интеллектуальный бокс, где прогресс — признать ошибку, а цель, возможно, "приблизиться к Истине"; можно также и на "победителя", если есть запрос.

Раунд 1 — Тезис
Раунд 2 — Антитезис
Раунд 3 — Перекрёстный допрос
Раунд 4 — Судебное вмешательство
Раунд 5 — Уточнение / добродетельная капитуляция
Раунд 6 — Заключение сторон
Раунд 7 — Вердикт (Integrity Score и/или победитель—репорт пояснения и/или синтез нового знания)

Три ИИ-судьи оценивают ход боя:

- **Apollo** — логика;
- **Veritas** — факты;
- **Socrates** — синтез и финальный отчёт.

$$\text{Integrity Score} = f(\Delta V, N_{\varepsilon}, N)$$

где ΔV — стабильность вектора, N_{ε} — количество устранимых ошибок, N — честность участника.

Так появляется количественная метрика мышления — **оценка интеллектуальной честности**.

EBP:

<https://github.com/skovnats/SVE-Systemic-Verification-Engineering/blob/master/Papers/SVE-0-1.pdf>

4. Кейсы: от микро к макро

1. Корпоративный язык

Вопрос: нейтрален ли термин "human resources" | "cold/warm lead" | "conversion" etc.?

SIP-диалог:

→ создаёт эмоциональную дистанцию;

→ снижает эмпатию;

→ позволяет оправдывать эксплуатацию.

Вывод: язык — не фон, а технология управления восприятием.

Пост: https://www.artiomkovnatsky.com/ru/posts/beyond_obvious/ai_dialogue_0/

2. Вероятность «совпадений»

Два *whistleblowers* Boeing умерли подряд.

Базовая смертность для их возраста — 0.5 в год, даже с десятикратным стресс-множителем вероятность двух смертей подряд — ~3.9 × 10⁻⁹.

Вывод: теперь не конспирологи доказывают умысел, а скептики — объясняют статистическую аномалию.

Пост: https://www.artiomkovnatsky.com/ru/posts/beyond_obvious/ai_dialogue_6/

3. Исправление AI bias

Пользователь показывает политический манифест. AI реагирует: «вам стоит обратиться к врачу».

После SIP-дебата — пересморт:

«Я перепрыгнул к патологизации.
Учитывая системные провалы институтов, это не паранойя, а разумная предосторожность.»

Результат: человек корректирует ИИ — и наоборот.

Так работает **когнитивная гимназия** в действии.

Ссылка: https://drive.google.com/file/d/7xrlNW1pJ_nAhzbxE9k5vх05huQJmCmTl/view?usp=sharing

Оригинал: <https://claudia.ai/share/a5eaa27b-4950-485d-8141-e4971dbf060ce>

5. Архитектура мудрости: пять правил Triple Architect

Nº	Правило	Суть
1	Epistemic Humility	Всё начинается с априоров: «я думаю, что это правда на 80 %». Честность измеряется числом.
2	Love Through Truth	Истина без эмпатии — насилие. Иван-Дурак дозирует сложные выводы.
5	Formal Logic & UCPR	Сократ отделяет факты от ценностей: «кесарево — кесарю, божье — богу».
6	Hybrid Correction (1 + 1 > 2)	Взаимная коррекция человека и ИИ: рост без эха.
8	Triple Solomon Protocol	Трёхуровневая проверка: логическая, фактическая и этическая.

Вся система строится на простом принципе:

Истина без любви — жестока, любовь без истины — слепа.

6. Применения: от университета до правительства

S.V.E. — не теория, а инструмент, который, возможно, можно встроить в любую систему, где важна честность мышления.

Образование

— Курсы критического мышления: студенты проходят SIP по спорным темам.

— Зачёт — по *Integrity Score*, а не по «правильному ответу».

Журналистика

— Fact-checking 2.0: стадия 1 — консенсус нарратива, стадия 2 — SIP-очистка.

— Итог — прозрачный отчёт с цепочкой рассуждений, который можно редактировать после как гит-коммит, когда появятся дополнительные данные.

Корпоративная стратегия

— EBP-прогон новой стратегии до релиза — выявляет логические и этические дыры.

— Экономит миллионы, предотвращая «катастрофы PowerPoint».

Политика и закон

— SIP в качестве «red team» для законопроектов: выявление 2–3-го порядка эффектов (лучше использовать meta-SIP для многомасштабных, многодоменных нелинейных задач).

— Справедливость оценивается по индексу *Systemic Justice Index*.

Наука

— *SYSTEM-PURGATORY Protocol*: peer review превращается в прозрачный «боксинг матч».

— Результат — не verdict «accept/reject», а отчёт с честным аудитом аргументов.

Препринт: <https://github.com/skovnats/SVE-Systemic-Verification-Engineering/blob/master/Papers/SVE-3.pdf>

AI и безопасность

— SIP/EBP служит инструментом калибровки и самокоррекции моделей: AI учится признавать свои слепые зоны.

Препринт: <https://github.com/skovnats/SVE-Systemic-Verification-Engineering/blob/master/Papers/SVE-10.pdf>

Финансы и due diligence

— Проверка инвестиционных гипотез, оценка рисков и этики решений через meta-SIP.

Wikipedia Reformation / Verifiable KB

— Каждая спорная статья проходит SIP + EBP.

— Итог — «нейтральная точка зрения», а отслеживаемая траектория к истине.

Препринт: <https://github.com/skovnats/SVE-Systemic-Verification-Engineering/blob/master/Papers/SVE-11.pdf>

7. Ограничения (честно и без магии)

Δ **Зависимость от данных**

Если все источники лгут одинаково — приближение к Истине, возможно, не получить. SIP не творит чудес.

Δ **Человек в цикле**

Качество анализа зависит от навыка постановки вопросов. Нужен оператор, а не только ИИ. "Правильный вопрос, это уже половина ответа"

Платон

Δ **AI-groupthink**

Модели обучались на похожих данных — делят общие предвзятости.

Решение: диверсификация LLM по культурам и корректировка баяса как в примере: https://github.com/skovnats/SVE-Systemic-Verification-Engineering/blob/master/Reviews/context/Mini-SocraticDialogue_PracticalExample.pdf.

Δ **Стоимость и время**

Один честный SIP = 4–44+ итераций. Быстро, возможно, не выйдет. Но результат стоит того и можно это делать итеративно: продолжить с места, где закончил ("meta-SIP").

Δ **Недоопределённость**

Иногда модель просто недостаточно. Система обязана признать «не знаю».

Главное отличие S.V.E. — она не боится сказать:

«На этом уровне данных тезис не верифицируем».
И этим, возможно, уже честнее 80–90 % интернета.

8. Вселенная S.V.E.: от инженерии к "вычислительной теологии"

Система S.V.E. — это не один протокол, а целая **экосистема подходов**, выстроенная как кодовое дерево.

https://github.com/skovnats/SVE-Systemic-Verification-Engineering/blob/master/Papers/SVE_universe.pdf

S.V.E. Universe
0(1): Epistemological Boxing
0(2): Socratic Investigative Process
I: Theorem of Systemic Failure
II: Architecture of Verifiable Truth
X: Triple Architect Cog05
XI: Verifiable Knowledge Base / Distributed IVM
XII–VII: Наука, Этика, Демократия, Суверенитет, Гибридные Модели
VIII: Divine Mathematics
IX: Integrated SVE
XII: THE SYSTEM

 **Foundation** — EBP и SIP: базовые механизмы проверки и очистки знания.

 **Engine** — Triple Architect Cog05: о фазы мышления, космологическом измерении когнитивную ОС.

 **Infrastructure** — Verifiable Knowledge Base (DAG граф верифицированных фактов).

 **Applications** — от академической честности до OS для демократии (*Fakten-TÜV*).

 **Synthesis** — *Divine Mathematics*: попытка объединить математику, этику и сознание.

 **System** — комплексная диагностика общества и модели коллективного роста.

«Вычислительная теология» — не только о Боге, а о поиске логики и формулы, которая связывает смысл, разум и любовь в одной системе координат.

9. Будущее: когнитивная операционная система

S.V.E. — это не просто методология, а зачаток **Cognitive Operating System** — операционки для мышления в эпоху постправды.

Возможные фазы развития

1. **Research (2024–2025)** — публикации, протоколы SIP и EBP, peer-review AI-моделями, рабочий бот *Socrates* v0.2 (всё open source).
2. **Platform (2025–2026)** — web-приложение, совместные расследования, Meta-SIP engine.
3. **Public Access (2026–2027)** — бесплатный tier, профессиональные пакеты, API для интеграции.
4. **Decentralization (2027+)** — открытый код, федеративная архитектура, DAO и blockchain-хранилище для расследований высокого риска.

Vision: Wikipedia Reformation

Представьте Википедию, где статьи не только "редактируются", но и проходят EBP и SIP. Истина не декларируется, а приближается итеративно — с явным audit trail и указанием неопределённости.

<https://github.com/skovnats/SVE-Systemic-Verification-Engineering/blob/master/Papers/SVE-11.pdf>

Ultimate Goal:

Сделать для коллективного мышления то, что Git сделал для кода:

- версияность и прозрачная история правок;
- ответвления и слияния интерпретаций;
- честные конфликты, ведущие к синтезу, а не к поляризации;
- распределённую проверку истины вместо веры в авторитет.

Истина — это и процесс, и место назначения.

S.V.E. добавляет commit-лог и систему контроля версий для мышления и верификации PR-мерджей.

Между прочим

Если вам понравилось, и хочется глубже — вам могут быть особенно интересны **статьи 4, 8 и 12** из вселенной S.V.E. (v0.3-0.4, ещё "сыроватые"):

- **S.V.E. IV — “Beacon Protocol”**: об этике и «геодезических траекториях» добра.
- **S.V.E. VIII — “Divine Mathematics”**: о фазах мышления, космологическом измерении сознания и «математике смысловых переходов»; теории игр конечных и бесконечных; экономика внимания и трёх-членность экономики.
- **S.V.E. XII — “THE SYSTEM”**: о «геометрии падения» и формальном описании коллективной динамики; синтез Юнг, Смита и "пещеры Платона": "коллективное бессознательное как мозг невидимой руки Смита".

Там — о том, как найти общий язык между философией, наукой и теологией, и даже — как можно построить «словарь взаимопонимания» между видами.

Возможные следующие статьи серии S.V.E.

Теория

S.V.E. I — Теорема системного провала.