

S.V.E.: как проверять мысли так же строго, как код — SIP/EBP, «Git для итеративных фактов»

Основные материалы v0.3-0.4

 **GitHub репозиторий:**
github.com/skovnats/SVE-Systemic-Verification-Engineering
<https://github.com/skovnats/SVE-Systemic-Verification-Engineering/tree/master/Papers>
Препринты (часть — в модерации на arXiv, остальные — в подготовке), структура дисциплины и полная документация.
 Лицензия: **S.V.E. Public License v1.3** — свободно для некоммерческого использования.

 **Независимые AI-рецензии:**
chat.openai.com/g/g-68f1fc98489483191a1cc038db8e3422b-sokrat-socrates-bot-v0-2
<https://github.com/skovnats/SVE-Systemic-Verification-Engineering/tree/master/Reviews>
Пять независимых моделей SVE-делали ревью каждой статье и Qwen выносил финальный "вердикт" по результатам 4-6-х ревью.

 **Бот "Socrates" (рабочий прототип):**
[chat.openai.com/g/g-68f1fc98489483191a1cc038db8e3422b-sokrat-socrates-bot-v0-2](https://chatgpt.com/share/68f2558c-add8-8003-91d8-ba4e7f03d6e1)
Содержит все материалы S.V.E. (кроме статей 10–12 — в процессе) и работает как **когнитивная гимназия** — переводит сложные философские и математические концепции на человеческий язык.

 **Пример взаимодействия:**
Что в вас интересного? Какие данные загружены?
<https://chatgpt.com/share/68f2558c-add8-8003-91d8-ba4e7f03d6e1>

TL;DR


- Проблема:** LLM уверенно ошибаются; люди подтверждают убеждения.
- Решение:** S.V.E. — процедура верификации мышления: не ответы, а **путь к ответу**.
- Инструменты:** **SIP** — итеративная очистка тезиса (в семантическом многообразии). **EBP** — «интеллектуальный бокс» со судьейской панелью.
- Метрика:** **Integrity Score** — количественная оценка честности рассуждения.
- Формат:** **когнитивная гимназия** — человек и ИИ взаимно тренируются.
- Open-source:** код, статьи, диалоги, AI-рецензии, работающий бот.

1. Почему «спроси у ChatGPT» — это не решение

ChatGPT — не база знаний, а предсказатель слов (токенов). Он может объяснить квантовую механику, но также уверенно придумать несуществующую статью. Проблема не только в нём — мы сами подыгрываем: часто задаём вопросы, чтобы получить **подтверждение**, а не опровержение. Добавим шум соцсетей, политкорректность, коммерческие фильтры и встроенные смещения (bias) моделей — и получаем интеллектуальный Plinko, где жетон истины отскакивает от штырьков искажений. **Пример коррекции смещенных модели через SIP:**
https://github.com/skovnats/SVE-Systemic-Verification-Engineering/blob/master/Reviews/context/Mini-SocraticDialogue_PracticalExample.pdf

2. Решение: три персоны мудрости

S.V.E. предлагает не «ещё один ИИ-бот», а структуру верификации мышления:



- Сократ** — логик и скептик: спрашивает «почему ты так думаешь?» и проверяет факты.
- Соломон** — арбитр — оценивает не только логическую, но и нравственную корректность.
- Иван-Дурак** — эмпатический фильтр: гарантирует, что истина доставляется «чайными ложечками».

Главный принцип — **1 + 1 > 2**: человек и ИИ взаимно корректируют друг друга и вместе становятся умнее.

Как работает Тройной Архитектор

Каждый диалог с системой начинается с **оцифровки априорных убеждений**. Пользователь указывает до 7 гипотез — и оценку уверенности в каждой (например 0.8 ± 0.1). Так создаётся карта *Priors*, с которой система работает как байесовский аудитор: вероятности пересчитываются после каждого шага анализа и/или добавления новых входных данных (факты, ценности и т.д.).

Далее применяется **Пятиколоночная таблица аудита**, разделяющая всё, что обычно смешано:

1 — Caesar's	2 — Experts	3 — Divine / Values	4 — Blind Spots	5 — Final Weight
Факты и данные	Консенсус / модели	Ценности и аксиомы	Противоречия и стресс-тесты	Итоговый вес для синтеза

Такое разложение делает видимыми «смещённые аргументы» — где эмоция, а где доказательство. На этой основе строится **Solomonic Verdict** — взвешенное заключение, где логика, этика и контекст сходятся в едином выводе.

Система постоянно **перекалибрует глубину и тон**, отслеживая стиль, орфографию и ритм мышления собеседника.

Если человек растёт — ИИ понижает «скидку уверенности» (Dunning–Kruger correction) и увеличивает сложность.

В конце каждого цикла появляются две «сократовские подписи», я называю это «Сократовский хвостик» (поскольку Сократу приписывается фраза: "я знаю, что ничего не знаю"):


- Хвост человека:** предложение 1-3 факторов, которые он не **учёл**.
- Хвост бота:** вопрос о том, что сам ИИ мог **переоценить** или **упустить**.

Так закрывается петля 1 + 1 > 2: взаимная коррекция человека и машины.

3. Как это работает: два протокола

SIP — Socratic Investigative Process

Итеративная очистка нарратива-тезиса от ошибок. Каждое утверждение — это вектор в многомерном смысловом пространстве:



На каждой итерации система (Человек + ИИ) возможно находит конкретную ошибку — логическую, фактическую, контекстную — и "вычитает" её:

$$v(n+1) = v(n) - \varepsilon(n)$$

Простыми словами: каждое уточнение приближает нас к **устойчивому факту**. Сходимость означает, что при добавлении новых аргументов позиция больше не меняется — она прошла через фильтр логики, эмпатии и справедливости.

EBP — Epistemological Boxing Protocol

Если SIP — это очистка, то EBP — стресс-тест ("red-teaming"). Это интеллектуальный бокс, где прогресс — признать ошибку, а цель, возможно, "приблизиться к Истине"; можно также и на "победителя", если есть запрос.



Три ИИ-судьи оценивают ход боя:

- Apollo** — логика;
- Veritas** — факты;
- Socrates** — синтез и финальный отчёт.

$$\text{Integrity Score} = f(\Delta V, N\varepsilon, H)$$

где ΔV — стабильность вектора, $N\varepsilon$ — количество устранённых ошибок, H — честность участника.

Так появляется количественная метрика мышления — **оценка интеллектуальной честности**.

4. Кейсы: от микро к макро

1. Корпоративный язык

Вопрос: нейтрален ли термин "human resources" | "cold/warm lead" | "conversion" etc.? **SIP-диалог:**
→ создаёт эмоциональную дистанцию;
→ позволяет оправдывать эксплуатацию.
Вывод: язык — не фон, а технология управления восприятием.
Статья: https://www.artiomkovnatsky.com/ru/posts/beyond_obvious/ai_dialogue_0/

2. Вероятность «совпадений»

Два *whistleblowers* Boeing умерли подряд. Базовая смертность для их возраста — 0.5 % в год, даже с десятикратным стресс-множителем вероятность двух смертей подряд — ~3.9 × 10⁻⁹. **Вывод:** теперь не конспирологи доказывают умысел, а скептики — объясняют статистическую аномалию.
Статья: https://www.artiomkovnatsky.com/ru/posts/beyond_obvious/ai_dialogue_6/

5. Архитектура мудрости: пять правил Triple Architect

Nº	Правило	Суть
1	Epistemic Humility	Всё начинается с априоров: «я думаю, что это правда на 80 %». Честность измеряется числом.
2	Love Through Truth	Истина без эмпатии — насилие. Иван-Дурак дозирует сложные выводы.
3	Formal Logic & UCPR	Сократ отделяет факты от ценностей: «кесарево — кесарию, божье — богу».
6	Hybrid Correction (1 + 1 > 2)	Взаимная коррекция человека и ИИ: рост без эха.
8	Triple Solomon Protocol	Трёхуровневая проверка: логическая, фактическая и этическая.

Вся система строится на простом принципе:
Истина без любви — жестока, любовь без истины — слепа.

6. Применения: от университета до правительства

S.V.E. — не теория, а инструмент, который, возможно, можно встроить в любую систему, где важна честность мышления.

Курсы критиче

- Образование — Курсовые критические мышления: студенты проходят SIP по спорным темам.
- Зачёт — по *Integrity Score*, а не по «правильному ответу».

Журналистика

- Fact-checking 2.0: стадия 1 — консенсус нарратива, стадия 2 — SIP-очистка.
- Итог — нейтральная отчёт цепочки рассуждений, который можно редактировать после как гит-коммит, когда появятся дополнительные данные.

Корпоративная стратегия

- EBP-прогон новой стратегии до релиза — выявляет логические и этические дыры.
- Экономист миллионы, предотвращая «катастрофы PowerPoint».

Политика и закон

- SIP в качестве «red team» для законопроектов: выявление 2–3-го порядка эффектов (лучше использовать мета-SIP для многомасштабных, многодоменных нелинейных задач).
- Справедливость оценивается по индексу *Systemic Justice Index*.

Наука

- SYSTEM-PURGATORY Protocol*: peer review превращается в прозрачный «боксинг матч».
- Результат — не verdict «accept/reject», а отчёт с честным аудитом аргументов.
- Препринт: <https://github.com/skovnats/SVE-Systemic-Verification-Engineering/blob/master/Papers/SVE-3.pdf>

AI и безопасность

- SIP/EBP служит инструментом калибровки и самокоррекции моделей: AI учится признавать свои слепые зоны.
- Препринт: <https://github.com/skovnats/SVE-Systemic-Verification-Engineering/blob/master/Papers/SVE-10.pdf>

Финансы и due diligence

- Проверка инвестиционных гипотез, оценка рисков и этики решений через мета-SIP.

Wikipedia Reformation / Verifiable KB

- Каждая спорная статья проходит SIP + EBP.
- Результат: не «нейтральная точка зрения», а прослеживаемая траектория к истине.
- Препринт: <https://github.com/skovnats/SVE-Systemic-Verification-Engineering/blob/master/Papers/SVE-11.pdf>

7. Ограничения (честно и без магии)

Зависимость от данных

Если все источники лгут одинаково — приближение к Истине, возможно, не получить. SIP не творит чудес.

Человек в цикле

Качество анализа зависит от навыка постановки вопросов. Нужен оператор, а не только ИИ. "Правильный вопрос, это уже половина ответа"

Платон

AI-groupthink

Модели обучались на похожих данных — делят общие предвзятости.

Решение: диверсификация LLM по культурам и корректировка баяса как в примере: https://github.com/skovnats/SVE-Systemic-Verification-Engineering/blob/master/Reviews/context/Mini-SocraticDialogue_PracticalExample.pdf.

Стоимости и время

Один честный SIP = 4–44+ итераций. Быстро, возможно, не выйдет. Но результат стоит того и можно это делать итеративно: продолжить с места, где закончил ("мета-SIP").

Недоопределённость

Иногда данных просто недостаточно. Система обязана признать «не знаю».

Главное отличие S.V.E. — она не боится сказать:

«На этом уровне данных тезис не верифицируем». И этим, возможно, уже честнее 99 % интернета.

8. Вселенная S.V.E.: от инженерии к "вычислительной теологии"

Система S.V.E. — это не один протокол, а целая **экосистема дисциплин**, выстроенная как кодовое слово.

https://github.com/skovnats/SVE-Systemic-Verification-Engineering/blob/master/Papers/SVE_universe.pdf

1

S.V.E. Universe

2

0(1): Epistemological Boxing

3

0(2): Socratic Investigative Process

4

I: Theorem of Systemic Failure

5

II: Architecture of Verifiable Truth

6

X: Triple Architect CogOS

7

XI: Verifiable Knowledge Base / Distributed IVM

8

III–VII: Наука, Этика, Демократия, Суверенитет, Гибридные Модели

9

VIII: Divine Mathematics

10

IX: Integrated SVE

11

XII: THE SYSTEM

12

13

 **Foundation** — EBP и SIP: базовые механизмы проверки и очистки знания.

 **Engine** — Triple Architect CogOS: три архетипа мудрости, объединённые в когнитивную ОС.

 **Infrastructure** — Verifiable Knowledge Base (DAG граф верифицированных фактов).

 **Applications** — от академической честности до ОС для демократии (*Fakten-TÜV*).

 **Synthesis** — *Divine Mathematics*: попытка объединить математику, этику и сознание.

 **System** — комплексная диагностика общества и модели коллективного роста.

«Вычислительная теология» — не только о Боге, а о поиске логики и формулы, которая связывает смысл, разум и любовь в одной системе координат.

9. Будущее: когнитивная операционная система

S.V.E. — это не просто методология, а зачаток **Cognitive Operating System** — операционки для мышления в эпоху постправды.

Возможные фазы развития

- Research (2024–2025)** — публикации, протоколы SIP и EBP, peer-review AI-моделями, рабочий бот *Socrates* v0.2 (всё open source).
- Platform (2025–2026)** — web-приложение, совместные расследования, Meta-SIP engine.
- Public Access (2026–2027)** — бесплатный tier, профессиональные пакеты, API для интеграции.
- Decentralization (2027+)** — открытый код, федеративная архитектура, DAO и blockchain-хранилище для расследований высокого риска.

Vision: Wikipedia Reformation

Представьте Википедию, где статьи не только "редактируются", но и проходят EBP и SIP. Истина не декларируется, а приближается итеративно — с явным audit trail и указанием неопределённости.

<https://github.com/skovnats/SVE-Systemic-Verification-Engineering/blob/master/Papers/SVE-11.pdf>

Ultimate Goal:

Сделать для коллективного мышления то, что Git сделал для кода:

- версионность и прозрачная история правок;
- ответвления и слияния интерпретаций;
- честные конфликты, ведущие к синтезу, а не к поляризации;
- распределённую проверку истины вместо веры в авторитет.

Истина — это и процесс, и место назначения.
S.V.E. добавляет commit-лог и систему контроля версий для мышления и верификации PR-мерджей.

Между прочим

Если вам понравилось, и хочется глубже — вам могут быть особенно интересны **статьи 4, 8 и 12** из вселенной S.V.E. (v0.3-0.4, ещё "сыроватые"):

- S.V.E. IV — "Beacon Protocol"**: об этике и «геодезических траекториях» добра.
- S.V.E. VIII — "Divine Mathematics"**: о фазах мышления, космологическом измерении сознания и «математике смысловых переходов»; теории игр конечных и бесконечных; экономика внимания и трёх-членность экономики.
- S.V.E. XII — "THE SYSTEM"**: о «геометрии падения» и формальном описании коллективной динамики; синтез Юнг, Смита и "пещеры Платона"; "коллективное бессознательное как мозг невидимой руки Смита".

Там — о том, как найти общий язык между философией, наукой и теологией, и даже — как можно построить «словарь взаимопонимания» между видами.

Следующие статьи, возможно будут более узкой направленности...но это не точно: как будет позволять силы и время, практика сейчас приоритетней.

Systemic Verification Engineering — не про «правильные ответы».

Это про честный путь к ним.
Попробуйте.

И, как сказал бы Сократ, *начните с признания, что не знаете — чтобы узнать лучше*.

Licensed under **S.V.E. Public License v1.3** — бесплатно для некоммерческого использования, открыто для исследований, адаптаций и образовательных проектов.

Спасибо за Ваше время и внимание!

A.

Нажмите "/" для вызова меню

